

用 AI 智能体辅助经济学研究

代码仓库:

<https://github.com/hainingzhang/econresearch/>

张海宁

2026.9.

议程

01 AI 能力的跃迁

02 非结构化数据转化为经济学变量

03 大语言模型在经济学中的应用

04 经济学研究实战

05 智能体和大模型的选择

01

AI 能力的跃迁

快速演进和迭代中

AI 的能力的跃迁：换了五次挡



生成内容 → 理解世界 → 持续执行

智能体 ≠ 聊天机器人



聊天机器人

你问、它答（纯文本）
给建议，但不落地



智能体 (Agent)

能调用工具完成任务
写/跑代码、读写文件、联网、出图

智能体云端拥有：Bash、文件编辑、Python、联网、预览等多种工具，以及各种本地的工具（skills）。

关键差异：智能体能自主多步执行并产出文件，而不只是给建议。

传统研究的四个瓶颈

01

数据昂贵

人工搜集、录入和清洗消耗大量时间。

02

概念难测量

政策强度、企业预期等概念没有直接字段。

03

材料规模大

数万份文本难以依靠人工逐篇编码。

04

复现成本高

旧代码、数据口径和多轮检验难以管理。

AI 进入经济学研究的位置

01

经济问题

理论机制与可检验假设

02

数据材料

表格、文本、图像、网页

03

AI 测量

分类、抽取、嵌入、预测

04

计量识别

比较设计、估计与检验

05

经济解释

机制、边界与外推范围

AI 主要改变第 2 至第 4 步的执行能力

02

非结构化数据如何成为经济变量

文本、图像与网页记录，需要经过明确的测量过程才能进入模型

结构化数据与非结构化材料

材料	原始形式	可构造变量	经济学问题
政策文本	通知、办法、规划	政策工具与强度	政策是否影响创新
招聘广告	职位描述	技能、任务、薪资	AI 是否改变劳动需求
年报	经营讨论与披露	预期、风险、AI 投入	企业战略是否影响绩效
卫星图像	灯光与地表影像	活动强度、建成区	地区发展如何变化

例子：企业不确定性指数

研究问题：不确定性上升是否抑制资本开支和研发投入？

原始材料

- 上市公司年报
- 业绩说明会纪要
- 管理层对需求、政策和供应链的描述

研究变量

- 政策不确定性
- 需求不确定性
- 供应链风险
- 企业年份综合指数

步骤：

收集材料：抓取上千家上市公司近十年的年报和业绩说明会文字记录

文本识别：用关键词词典法（如"政策""监管""不确定"等词的共现）或者用大语言模型对每段管理层陈述做分类打标，判断该段落是否在表达"政策不确定性"的担忧

量化处理：统计某公司某年报告中，涉及政策不确定性的语句占全文的比例，或者用词频加权得到一个0-1的连续分值

构建面板变量：把这个分值按"企业-年份"整理成面板数据，形成一个可以放进回归模型的自变量

综合指数：类似地处理需求不确定性、供应链风险等维度，再加权合成一个"企业年份综合不确定性指数"

例子：夜间灯光补充地区经济测量

01

卫星影像

获得地区与年份的灯光或地表图像。

02

图像处理

识别光照强度、建筑扩张和道路变化。

03

地区指标

形成灯光、建成区或灾后恢复指标。

04

经济分析

与 GDP、贫困、迁移或政策冲击匹配。

经典例子

Henderson, Storeygard & Weil (2012, American Economic Review) 的研究：

他们发现很多发展中国家（尤其是非洲国家）官方GDP统计质量很差、甚至长期缺失，于是用夜间灯光增长率作为“真实经济增长”的代理变量，重新估计了这些国家过去几十年的经济增长率，结果发现不少国家官方公布的生长数据被系统性高估或低估了。

从原始材料到回归变量

01

定义概念

先写清理论概念与排除条件。

02

建立样本

人工标注一批代表性材料。

03

模型编码

按固定规则批量分类或抽取。

04

质量验证

评估准确率、一致性和分组误差。

05

形成变量

聚合到企业、个体或地区层级。

03

大语言模型在经济学研究中的应用

政策、企业、劳动与消费者研究，都可以使用同一套测量框架

五类典型的AI应用

领域	研究材料	AI 任务	后续方法
政策研究	法规与地方政策	工具、对象、强度	DID、事件研究
企业研究	年报与电话会议	预期、风险、投入	面板固定效应
劳动研究	招聘广告	技能、任务、薪资	工资回归、冲击设计
消费者研究	评论与投诉	情绪、质量、欺诈	需求与平台分析
调查实验	开放题与访谈	主题、态度、理由	实验与异质性分析

案例：招聘广告中的 AI 技能

研究问题

要求 AI 技能的岗位，是否存在工资溢价？

01

采集广告

岗位、城市、企业、薪资和完整描述。

02

提取技能

区分使用工具、开发模型与数据分析。

03

构造指标

AI 技能要求、技能层级、任务结构。

04

估计溢价

控制岗位、城市、企业和时间差异。

可审核的文本分类任务的定义（提示词）

任务：阅读招聘广告，只按下列规则输出 JSON

1. ai_skill_required: yes / no / unclear
2. skill_level: tool user / developer / researcher
3. evidence: 复制支持判断的原句
4. salary_min、salary_max: 无法确认则为 null
5. confidence: 0 到 1

禁止根据公司名称猜测，不得补全广告没有提供的信息。

大模型贯穿研究流程，但责任并不相同

01

文献

整理脉络，原文核验由研究者完成。

02

数据

抽取与清洗，口径由研究者确定。

03

建模

生成与运行代码，识别设计由研究者负责。

04

写作

组织表达，结论责任仍由作者承担。

变量测量完成后，模型估计、代码执行和结果留痕也可以交给智能体

智能体可以干什么

1

写代码并运行

Python / Bash

2

读写项目文件

data / scripts / reports

3

联网采集

API / 网页

4

统计与可视化

pandas / statsmodels / matplotlib

5

实时预览交付物

present_files

6

中文原生·分步对话

边讲边跑

04

经济学研究实战

最低工资政策与快餐店就业：DID 因果推断演示

代码仓库：

<https://github.com/hainingzhang/econresearch/>

研究例子：最低工资上调会改变就业吗？

1992年4月,新泽西州最低工资从每小时4.25美元上调至5.05美元, 而邻近的宾夕法尼亚州维持不变。Card 和 Krueger 利用这一“自然实验”(natural experiment), 在涨薪前后分别对新泽西州和宾夕法尼亚州边境地区的快餐店(如 Burger King、KFC、Wendy's、Roy Rogers)进行电话调查,收集就业数据。

我们比较政策前后：

新泽西州快餐店（处理组）
与宾夕法尼亚州东部快餐店（对照组）

的就业变化差异。

因变量

全职等价就业人数 FTE
(Full Time Equivalent)

$$\text{FTE} = \text{全职员工人数} + \text{管理人员人数} + 0.5 \times \text{兼职员工人数}$$

来源：Card, David, and Alan B. Krueger. 1994. “Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania.” *American Economic Review* 84 (4): 772–793.

一项研究如何被拆成可执行的任务

00 问题描述

研究人员负责定义问题、研究对象、因果逻辑和判断标准，数据来源，智能体负责执行数据、代码、检验和文档工作。
然后（用AI）生成以下的流水线（规划）：

01 数据下载

02 数据清洗

03 数据审计

04 描述性分析

05 识别假设评估

06 DID 回归

07 稳健性检验

08 撰写研究备忘录

要点： 每一步都留下依据，下一步才能复核上一步。

怎样用AI辅助写研究计划

- 1 把研究问题向AI描述：假设，数据，问题，目标等等
- 2 进行多轮对话，进一步确定研究细节和方法
- 3 【关键】让AI生成可让 Codex（或Claude，ZCode等智能体）执行的指令，参考提示词如下：

根据我们上面的讨论，生成可供codex执行研究计划的任务描述md文件。

- 4 检查 AI 生成的设计文件内容，可重复2-4步骤，让 AI 完善任务描述（研究设计）
- 5 可让换一个AI来检查确认，必要时可以手工修改研究计划
- 6 让智能体（codex，claude，Zcode等）执行研究任务
- 7 检查研究结果，按照情况修订研究计划，若有需要，可重复2-6步骤

识别策略：双重差分 DID

处理组

新泽西州
最低工资上调

Treat = 1

对照组

宾夕法尼亚州东部
未经历同一政策

Treat = 0

$$\text{DID} = (\text{处理组政策后} - \text{政策前}) - (\text{对照组政策后} - \text{政策前})$$

因果解释依赖哪些假设？

平行趋势

若没有政策，两组就业会沿着相近趋势变化

无重大溢出

新泽西政策不会直接改变对照组就业

同期冲击可控

没有只影响处理组的其他重大政策或冲击

样本可比

两组餐厅和调查方式具有基本可比性

注意：只有一个政策前时期时，平行趋势无法被充分检验。

数据获取：先保留原始数据

主数据源

Wooldridge njmin3 数据集

CSV 镜像：
vincentarelbundock.github.io/Rdatasets/csv/wooldridge/njmin3.csv

备用链接：
<https://raw.githubusercontent.com/AnthonyPuggs/CardKrueger1994Replication/main/njmin3.csv>

智能体记录

下载时间
文件大小
HTTP 状态
SHA-256 哈希

数据来源日志

- dataset: njmin3
- primary_url: <https://vincentarelbundock.github.io/Rdatasets/csv/wooldridge/njmin3.csv>
- fallback_url: <https://raw.githubusercontent.com/AnthonyPuggs/CardKrueger1994Replication/main/njmin3.csv>
- card_archive_validation_url: https://davidcard.berkeley.edu/data_sets/njmin.zip
- downloaded_at: 2026-09-16T06:13:29.254112+00:00
- source_used: 本地非空缓存 (原始备用来源: <https://raw.githubusercontent.com/AnthonyPuggs/CardKrueger1994Replication/main/njmin3.csv>)
- status: 已使用缓存; 未覆盖
- size_bytes: 25960
- sha256: 5dd549a40790d58cd1705474297ba9cf069e3dbc7fd561e4f6e14a1cde98a4d2

[docs/data_source_log.md](#)

数据从哪里来？如果链接失效，智能体是否会停止并报告，而不是编造数据？

清洗与审计：让数据问题显形

清洗

读取列名 → 识别州别和时期 → 构造 treat、post、did、restaurant_id、state、period → 保存 processed CSV

审计

检查重复键、缺失值、样本分布、极端值、前后期是否可匹配

数据审计

- 原始观测数：820；清洗后观测数：820。
- 处理组观测（NJ）：662；对照组观测（PA）：158。
- 重复的门店—时期键：0。两个时期均有观测的匹配门店：410 / 410。
- 小于 0 或大于 100 的 FTE 值：0。这些值仅作标记，不作修改。


州别—时期分布

	数量
('新泽西州', '政策后（1992 年 11 月）')	331
('新泽西州', '政策前（1992 年 2 月）')	331
('宾夕法尼亚州', '政策后（1992 年 11 月）')	79
('宾夕法尼亚州', '政策前（1992 年 2 月）')	79


outputs/data_audit.md

审计报告必须给数字，也必须写出处理规则。缺失值不能默认为 0。

描述性检查：先看图，再看回归



两州政策前后就业均值



处理组与对照组变化量

描述性图表回答“发生了什么”，DID 模型进一步回答“相对变化是多少”。

帮助我们了解数据结构和初步变化，不能单独证明因果关系。

识别假设检查：能否把变化解释为政策效应？

DID 不仅需要处理组、对照组和政策时间，还需要检查识别假设。

平行趋势	没有政策时，两组平均结果会沿相近趋势变化
组间可比性	处理组和对照组具有合理的比较基础
政策溢出	政策不会通过流动、迁移或竞争改变对照组
同期冲击	没有只影响处理组的其他重大政策或事件
样本流失	关店、拒访或缺失不会差异性地改变样本构成
处理暴露	处理变量真正代表了政策影响的对象和强度

当前案例只有一个政策前时期：不能正式检验平行趋势，只能把它作为识别假设并报告限制。

DID 回归：交互项是核心

$$fte_{it} = \alpha + \beta \text{Treat}_i + \gamma \text{Post}_t + \delta (\text{Treat}_i \times \text{Post}_t) + \varepsilon_{it}$$

Treat

政策前两组的平均差异

Post

对照组前后变化

Treat × Post

DID：政策带来的相对变化

报告系数、标准误、置信区间、p 值、观测数，并同时解释统计显著性与经济显著性。

稳健性检验：结果是否依赖一种方法？

建议让智能体至少完成四项检查

- 1 替代就业指标（若数据提供）
- 2 直接使用就业变化量计算 DID
- 3 异常值敏感性分析
- 4 州别或处理标签随机置换检验

检验做不出来时要解释原因，不能用“稳健”代替证据。

检验	DID / 处理组变化估计	细节
主回归的未调整 DID	2.754	结果变量完整的观测行
剔除 FTE 在第 1--99 百分位数之外的观测	1.170	n=778；敏感性检验，不是首选估计量
匹配门店变化 DID	2.750	n=384 家匹配门店
门店标签置换	双侧 p=0.0182	5,000 次固定数量的随机分配；随机种子 20260916

outputs/robustness_results.md

撰写研究备忘录：把证据组织成结论

研究备忘录不是重复粘贴回归表，而是回答：研究发现了什么、依据是什么、不能说明什么。

研究问题与背景	说明政策、处理组、对照组和研究对象
数据与变量	说明来源、样本量、FTE 定义、缺失和清洗规则
识别策略	解释 DID 公式、反事实和因果解释所依赖的假设
结果与稳健性	报告 DID 系数、标准误、置信区间，并比较替代设定
局限与建议	区分相关和因果，说明平行趋势无法检验的影响

智能体的最后一步：读取审计、回归和稳健性结果，自动生成一份可追溯的中文 `research_memo.md`。

智能体交付：一套可复现的研究项目

README.md：运行说明

docs/：研究计划、数据字典、模型说明

data/：原始数据与清洗数据

src/：按阶段组织的脚本

outputs/：审计、回归表、图表、研究备忘录

一键复现

bash run_all.sh

```
.
├── minimum_wage_did_agent_task.md  # 项目任务说明
├── minimum-wage-did-demo/
│   ├── data/                      # 原始和清洗后的数据
│   ├── docs/                      # 数据来源、研究计划、分析规格与可复现性记录
│   ├── outputs/                   # 回归表、图形、诊断、稳健性结果和研究备忘录
│   ├── src/                      # 七个顺序执行的分析脚本
│   ├── requirements.txt           # Python 依赖
│   └── run_all.sh                 # 一键复现入口
```

五句话概括


- 1 人做设计，智能体做执行。
- 2 一套可复用的9步研究流水线。
- 3 智能体可以调用工具，执行连续的研究工作流，不只是生成代码。
- 4 因果推断的可信度来自研究设计、数据审计和识别假设。
- 5 研究结果不一定能跑出“显著”——好的研究不一定支持假设。

05

智能体和大模型的选择

多种任务，多种组合

智能体的架构



怎样选择智能体和大模型



大模型和智能体的选择

工具	定位	适合任务	主要约束
Claude Code (Opus,Sonnet,Fable)	实证研究主 Agent	旧代码、复现、多轮检验	版本漂移、默认参数与数据合规
Codex (GPT,GLM,DEEPSEEK)	研究工程 Agent	数据管道、复杂脚本、调试	需写明计量规范、权限和环境
Kimi Code (K3,DeepSeek)	国内环境替代	中文材料与常规实证流程	统计包支持、版本和执行结果需实测
Zcode (GLM,DeepSeek)	内网与私有化选项	敏感企业数据、受限网络	依赖维护、模型版本与审计成本
WorkBuddy (HY3,HY4,DeepSeek等)	研究工作流与交付 Agent	任务拆解、项目文件管理、研究备忘录与协作交付	不替代 Stata/R/Python 执行层；需通过 Skill/连接器接入脚本，并人工核验数据权限与研究结论

其他资源：

Workbuddy 网页版：<https://www.workbuddy.cn/app>
豆包网页版：选择 “新工作任务” ， <https://www.doubao.com/chat>
其他 GLM，月之暗面等都有agent模式，费用各异

大模型和智能体的配合

大模型 / 智能体	强	中	简单
大模型	Claude系列模型 Fable, Opus, Sonnet OpenAI GPT系列: Astra, Sol, Terra, Luna	GLM, DeepSeek, Qwen, Kimi	豆包, 混元, 小米
智能体 (Agent)	Claude Code, Codex	Zcode, Kimi, Qoder, Code Buddy	DeepSeek Harness, Trae

写代码，做研究：强模型 + 强 Agent

调研，杂活：强模型 + 简单 Agent

创意写作：中文模型 + 简单 Agent

大模型决定能力的上限

智能体决定能力的下限

其他技巧(1)

CLAUDE.md / AGENTS.md 固定项目边界

```
# Project rules
- Never modify data/raw.
- Read research_plan.md and codebook.md before analysis.
- Stop if firm-year is not unique or policy timing is ambiguous.
- Use city-clustered standard errors in the main specification.
- Label exploratory results; do not write causal claims automatically.
- Every table and figure must be rebuilt by scripts/run_all.sh.
```

CLAUDE.md / AGENTS.md 保存稳定事实；重复执行的程序放进 skill

其他技巧(2)

DID skill: 把计量规范写成执行程序

```
---  
name: did-analysis  
description: Audit and run panel DID. Use for staggered policy adoption, event studies, and DID robustness checks.  
disable-model-invocation: true  
---  
1. Read research_plan.md.  
2. Audit panel keys, missingness, treatment timing and never-treated units.  
3. Stop and report blockers before estimation.  
4. Run the preregistered baseline, event study and named robustness checks.  
5. Save code, tables, figures, diagnostics and decision_log.md.  
6. Separate estimates from causal interpretation; list assumptions still required.
```

其他技巧(3)

第三方 Skill 的安装前检查

01

读 SKILL.md

检查触发条件、指令、权限和自动执行范围。

02

读全部脚本

查看 shell、Python、R、Node 和编译代码。

03

查外部访问

识别下载、上传、网络服务与环境变量读取。

04

隔离试运行

使用模拟数据、最小权限和无敏感凭证环境。

05

固定版本

记录提交哈希、依赖版本和本地修改。

市场上架、安装量和作者描述都不能替代源码审计

其他技巧(4)：直接执行代码与安装 Skill 对比


比较维度	对话中直接执行代码	安装 Skill
安装与配置	不需要；直接说明数据和模型	下载到本地并配置依赖
方法覆盖	由 Python 生态和现场代码决定	由 Skill 作者写入的范围决定
可信度	成熟库可查，但研究设计仍需确认	维护质量不一，需审核源码与权限
灵活性	可根据数据即时调整	流程更固定，适合重复执行
可复现性	主动保存脚本、环境和日志	可内置模板、检查点和交付规范
可审计性	未保存 Prompt 和环境时容易丢失过程	流程可固定，但未经源码审计仍有黑箱风险

直接执行更灵活，Skill 更容易固化流程；两者都需要保存证据和人工审核。
可考虑用自定义的 skill 固化以跑通的流程。

谢谢!



公众号：亨利笔记



公众号：亨利随想